Modelo final: E5 con log(precio), regresión lineal de log(precio) con la especificación E4 de la Parte 2 más estrato × área (interacciones con el tipo, polinomios del área y de las coordenadas, habitaciones, estrato, año y distancias), reajustada con todo el entrenamiento. **RMSE de validación:** 181,82 millones de pesos.

¿Cuánto vale una vivienda en Cali?

Proyecto de machine learning: predicción del precio de la vivienda

Universidad Icesi — Maestría en Economía · Big Data y Machine Learning para Economía Aplicada

Elkin Mola

12 de noviembre de 2026

---

1. La referencia y la regresión lineal

(a) Carga de datos y análisis exploratorio

Tabla 1. Descripción de la muestra

	Valor
Muestra	
Avisos de entrenamiento	15.277
Avisos de prueba	3.819
Precio en el entrenamiento (millones COP)	
Media	391,0
Desviación estándar	338,8
Mediana	290
Mínimo	50,0
Máximo	2.500
Tipo de inmueble (% del entrenamiento)	
Apartamento	55,1
Casa	44,9

Nota:
Precios en millones de pesos corrientes.

La **Tabla 1** presenta la estructura general de la muestra de los avisos de venta de vivienda en Cali. La sumatoria del conjunto de datos es de 19.096 observaciones, las cuales se dividen en un 80% entrenamiento y 20% de muestra.

Ahora bien, como se usarán cuatro quintos de dichos datos para construir el modelo, solo se analizan las medidas de tendencia central y dispersión de este subgrupo.
Como puntos claves tenemos:

- Gran brecha entre la media y la mediana; además de notable distancia entre el mínimo y el máximo de los datos. Esto confirma una fuerte asimetría positiva y una elevada heterogeneidad en el mercado inmobiliario de la ciudad (*véase Figura 1, panel B*).
- Hay predominancia de apartamentos sobre las casas, lo cual será un atributo determinante del tamaño de la vivienda (el área construida) y, con él, del precio.

Tabla 2. Valores faltantes por variable y muestra

	Entrenamiento		Prueba	
Variable	Avisos	%	Avisos	%
barrio	11.765	77,0	2.935	76,9
habitaciones	6.172	40,4	1.533	40,1

Nota: Nota: Los valores faltantes de precio en la prueba corresponden a la muestra oculta: ese precio no se usa para ajustar ni para elegir modelos.

La Tabla 2 presenta la proporción de valores faltantes en las variables del conjunto de datos. De este análisis destacan dos aspectos clave:

- Simetría entre muestras: La proporción de datos faltantes es prácticamente idéntica en el entrenamiento y en la prueba ($\sim 77,0\%$ en barrio y $\sim 40,3\%$ en habitaciones). Esto confirma que la pérdida de información es uniforme y que la partición de los datos se realizó sin sesgos.
- Implicaciones para el modelaje:
  - Uso de coordenadas (lon y lat): La alta ausencia de etiquetas en barrio ($77,0\%$) hace inviable usar esta variable. Por ello, se utilizan la longitud y la latitud (completas al 100%) para capturar el efecto de la ubicación de forma continua.
  - Imputación de características físicas: Para no perder el $40,4\%$ de la muestra por la variable habitaciones, se requiere imputar sus vacíos (por ejemplo, con la mediana) calculados estrictamente dentro de cada pliegue para evitar la filtración de datos.

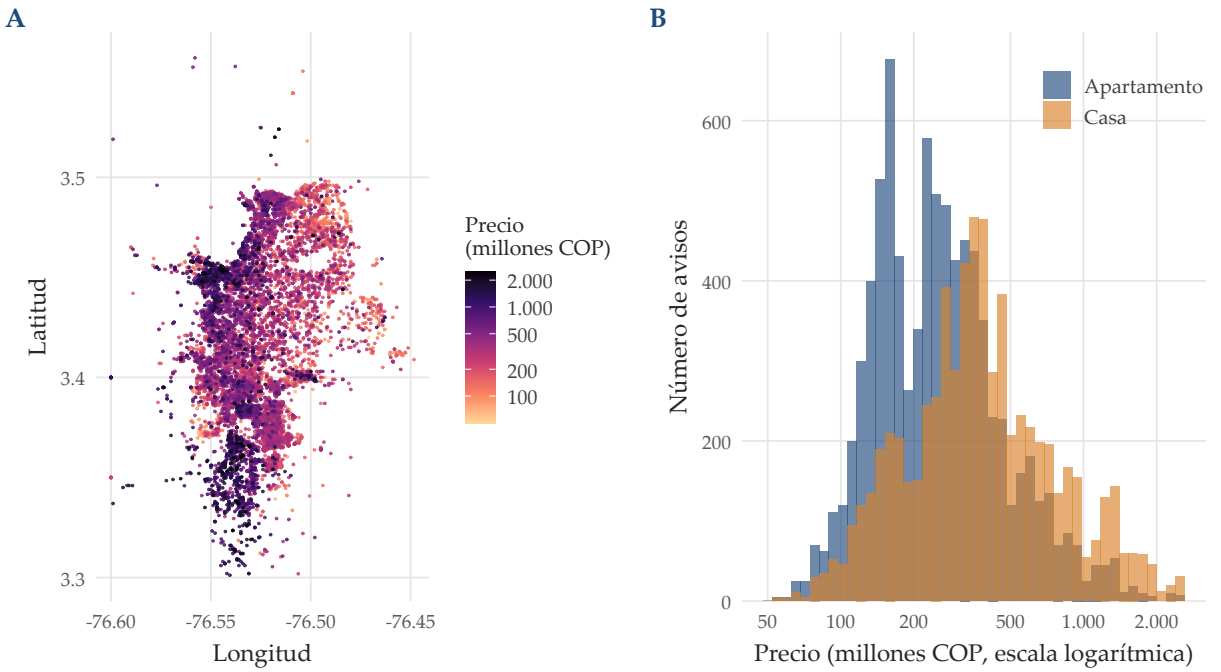


Figura 1. Precios de los avisos de entrenamiento. Panel A: ubicación de cada aviso, con el color según su precio (escala logarítmica). Panel B: distribución del precio por tipo de inmueble (escala logarítmica). Fuente: vivienda_cali.rds.

Anotaciones iniciales de estas imagenes:

- **Ubicación de los precios (Panel A):** El mapa refleja una clara división en la ciudad. Las viviendas más caras (los puntos más oscuros) se concentran en el Sur y en el Oeste de Cali, mientras que las de menor precio (los puntos más claros) predominan en el Oriente y en el Norte.
- **Diferencia entre apartamentos y casas (Panel B):** En general, los apartamentos son más económicos que las casas. Su distribución está más hacia los valores bajos, lo que encaja con una oferta de vivienda más económica. Por su parte, las casas alcanzan precios mucho más altos y tienen mayor variación entre sí. Se usa escala logarítmica para hacer una 'Normalizacion' a los precios.

(b) Modelos base y validación (M0, M1, M2)

Tabla 3. Métricas de validación de M0, M1 y M2 (primeras filas de la tabla de modelos)

Modelo	RMSE de validación	MAE de validación	R^2 de validación
M0: media del entrenamiento	340,94	230,87	-0,00
M1: recta con el área	234,14	146,12	0,53
M2: área, baños, tipo y coordenadas	212,43	130,79	0,61

Nota: RMSE y MAE en millones de pesos. Ajuste: 12.221 avisos; validación: 3.056 avisos (20 % del entrenamiento, semilla 12345). R^2 contra la media de la validación (yardstick::rsq_trad_vec).

Nota: Separamos el 20 % de los datos de entrenamiento para validación interna usando una semilla fija (`12345`). La Tabla 3 presenta las métricas de validación de los tres modelos.
Resultados:

- **Modelo de referencia (M_0)**: El asignar el precio promedio a todas las viviendas nos da un RMSE, MAE y R^2 como línea base de error sin utilizar ningún predictor.
- **Modelo con Área (M_1)**: Al incluir un los metros cuadrados al modelo el RMSE se reduce en un 31,3%; el MAE en un 36,77%. Con una sola variable, el modelo logra explicar el 53% de la variabilidad del precio.
- **Modelo completo (M_2)**: Al sumar los baños, el tipo de inmueble y la ubicación en el mapa, el modelo da un salto importante en precisión: el error promedio baja a 212,4 millones de COP y el error típico absoluto a 130,8 millones. Con esto, el modelo pasa a explicar el 61,2% de las variaciones del precio, logrando reducir el error del promedio inicial en casi un 38%.

(c) Diagnósticos para el modelo M2

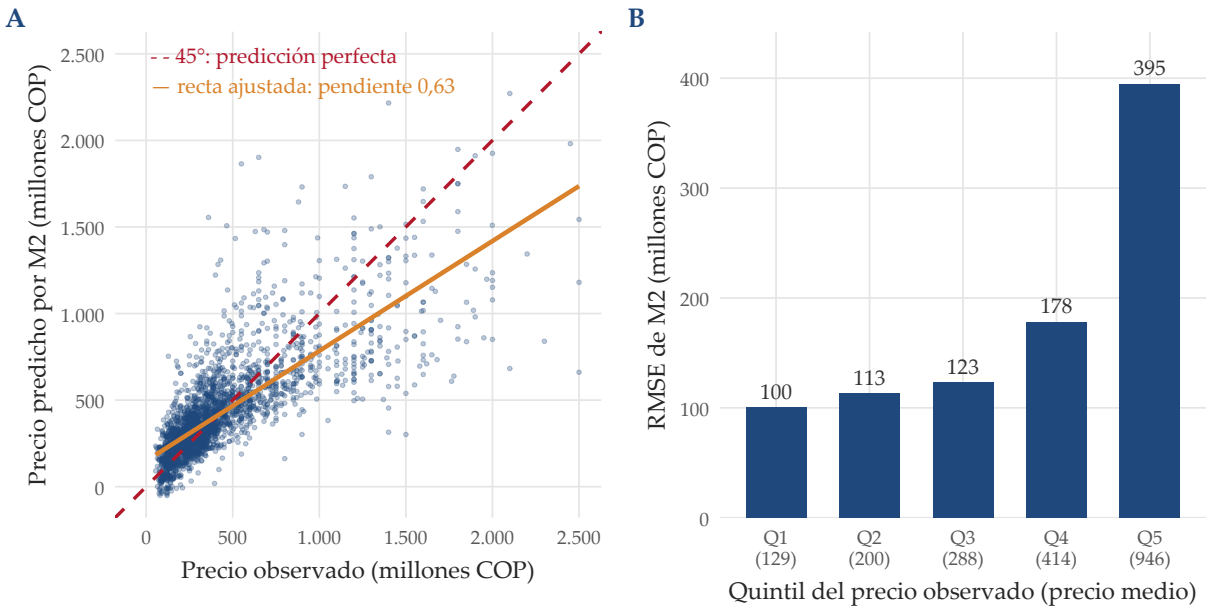


Figura 2. Diagnósticos de M2 en la validación. Panel A: precio predicho contra observado; la línea roja punteada es la predicción perfecta (45 grados) y la naranja, la recta ajustada entre los dos. Panel B: RMSE por quintil del precio observado; entre paréntesis, el precio medio de cada quintil.

Ahora bien, al graficar los precios predichos vs. los observados, la recta de tendencia ajustada (naranja) tiene una pendiente de 0.63, situándose por debajo de la línea ideal de 45° (véase Panel A).

Lo anterior evidencia un claro sesgo en el modelo M_2: sobreestima el valor de los inmuebles económicos y subestima fuertemente las viviendas más costosas. En términos simples, por cada millón adicional en el precio real de una propiedad, el modelo solo incrementa su predicción en 630.000.

Por otra parte, al analizar el Panel B, en las propiedades más económicas (primeros tres quintiles), el error del modelo se mantiene bajo y estable con un RMSE de entre 100 y 123 millones. Sin embargo, a medida que aumenta el valor de la vivienda, las fallas crecen: el error sube a 178 millones en el cuarto quintil y se dispara a 395 millones en el quinto quintil, afectando fuertemente la predicción de las casas más caras. Por tal razón, aunque el modelo M_2 predice con precisión aceptable las viviendas económicas y de precio medio, una regresión lineal simple es insuficiente para los inmuebles de lujo. Este enfoque se queda corto para capturar la alta variabilidad y las características únicas de las propiedades de mayor valor.

Tabla 4. Rendimiento de M2 por quintil del precio observado

			Precio medio		Error		
Quintil	Rango de precio	Avisos	Observado	Predicho	RMSE	MAE	RMSE / precio (%)
Q1	55 – 160	612	129,3	179,8	100,4	78,6	77,7
Q2	160 – 245	611	200,0	261,3	113,1	82,1	56,6
Q3	245 – 340	611	288,2	331,3	122,9	85,0	42,6
Q4	340 – 540	611	413,5	460,7	178,2	117,3	43,1
Q5	542 – 2.500	611	945,5	768,7	394,9	291,0	41,8

Nota: Valores en millones de pesos, sobre los avisos de validación. La última columna divide el RMSE del quintil por su precio observado medio.

Al analizar los resultados por rangos de precio, queda claro que el Modelo 2 sufre una fuerte compresión hacia la media: tiende a inflar el valor de las viviendas más baratas y a recortar el de las más caras. En el primer quintil (Q1), el modelo predice en promedio 179,8 millones de COP cuando el valor real es de 129,3 millones (sobreestimación). En el otro extremo (Q5), se queda corto por casi 177 millones en las propiedades de alta gama.
Aunque el error absoluto en dinero se dispara en las casas más costosas (alcanzando un RMSE de 394,9 millones), el golpe proporcional es mucho peor en las viviendas económicas, donde el error llega a representar un 77,7% del valor del inmueble. Esto deja en evidencia que una regresión lineal simple no logra responder bien en los extremos del mercado.

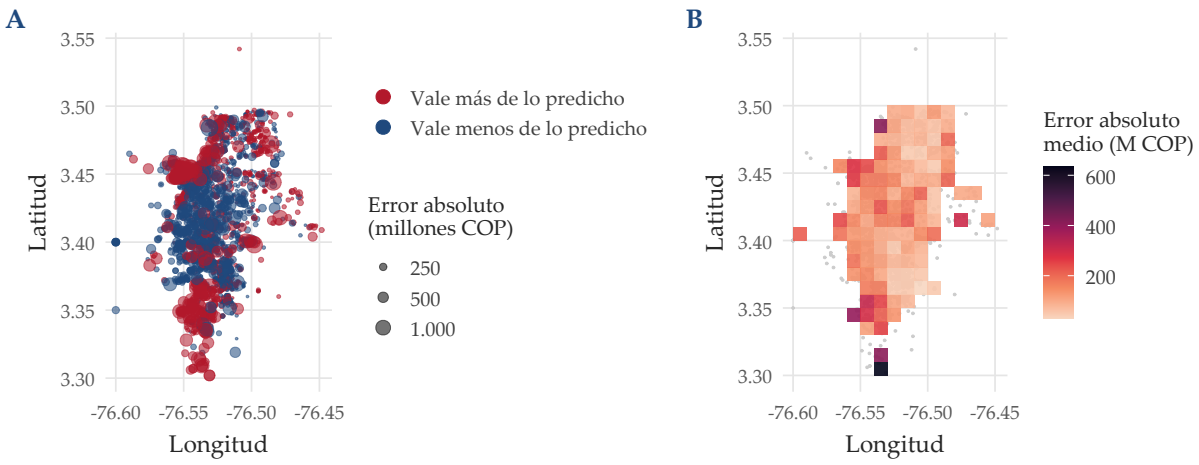


Figura 3. Errores de M2 en el mapa (avisos de validación). Panel A: residuo de cada aviso (observado menos predicho); el color indica el signo y el tamaño, el error absoluto. Panel B: error absoluto medio por celda de 0,01 grados (cerca de 1,1 km), en las celdas con al menos cinco avisos; en gris, los avisos de validación.

La **Figura 3** muestra que los errores del modelo no ocurren al azar, sino que se agrupan por zonas: si el modelo se queda corto con el precio de una casa en el Sur, probablemente también se quedará corto con sus casas vecinas.
Si usáramos una validación cruzada aleatoria tradicional, el resultado sería engañosamente optimista, porque el modelo estaría evaluándose con casas justo al lado de las que usó para entrenar.

(d) Cuánto reduce el error cada modelo

Tabla 5. Reducción del error de validación

		Reducción del RMSE	
Modelo	RMSE de validación	Frente a M0 (%)	Frente al modelo anterior (%)
M0: media del entrenamiento	340,9	—	—
M1: recta con el área	234,1	31,3	31,3
M2: área, baños, tipo y coordenadas	212,4	37,7	9,3

Nota: RMSE en millones de pesos. La reducción es 1 menos el cociente de los RMSE, en porcentaje.

- M_1 (área construida) reduce el RMSE un 31,3% frente a la media (M_0), bajándolo de 340,9 a 234,1 millones de COP.
- M_2 (área, baños, tipo y coordenadas) logra una reducción acumulada del 37,7% frente a M_0, situando el RMSE en 212,4 millones.
- La mejora marginal entre M_1 y M_2 es de apenas el 9,3%, evidenciando retornos decrecientes.Esto sugiere un techo predictivo cercano al 61% de la variabilidad (R^2) con la información estructurada del problema inicial.
- El error de **~212 millones** que queda sin explicar demuestra que detalles invisibles en un anuncio (como los acabados, el estado de la casa o el regateo) le ponen un freno a la precisión.

2. Validación y regularización

(a) Validación cruzada con cinco pliegues aleatorios

Tabla 6. RMSE de M1 y M2 con cinco pliegues aleatorios

	Avisos validados	M1	M2
Validación cruzada, 5 pliegues aleatorios			
Pliegue 1	3.056	243,5	219,1
Pliegue 2	3.056	228,1	203,4
Pliegue 3	3.055	236,4	212,2
Pliegue 4	3.055	240,1	214,7
Pliegue 5	3.055	245,9	225,8
Resumen entre pliegues			
Promedio	—	238,8	215,0
Desviación estándar	—	7,0	8,3
Parte 1			
Validación de la Parte 1 (80/20)	3.056	234,1	212,4

Nota: RMSE en millones de pesos. Cada pliegue se valida con los modelos ajustados en los otros cuatro (15.277 avisos de entrenamiento, semilla 12345).

La Tabla 6 presenta el RMSE de los modelos M_1 y M_2 con validación cruzada de cinco pliegues aleatorios. Cada pliegue se valida con el modelo ajustado en los otros cuatro, de modo que todas las viviendas de entrenamiento se usan una vez para evaluar.
Resultados:

- **Modelo con Área (M_1)**: El RMSE promedio entre pliegues es de 238,8 millones de COP, con una desviación estándar de 7,0 millones.
- **Modelo completo (M_2)**: Al sumar los baños, el tipo de inmueble y la ubicación, el RMSE promedio baja a 215,0 millones de COP (desviación estándar de 8,3), es decir, cerca de un 10% menos de error que M_1.
- **Consistencia de la mejora**: M_2 gana en los cinco pliegues, y la diferencia entre ambos modelos varía poco de un pliegue a otro (entre 20,1 y 25,4 millones, con una desviación estándar de 2,1). Por tal razón, la ventaja de M_2 no depende de cómo se repartieron los avisos al azar.

Ahora bien, la desviación estándar de cada modelo muestra que, solo por el azar de la partición, el error de un mismo modelo puede variar entre 7 y 8 millones. Como ambos modelos se evalúan en los mismos pliegues, cuando un pliegue es más difícil de predecir el error sube en los dos; aun así, M_2 supera a M_1 en todos los pliegues.
Comparación con la Parte 1: La validación 80/20 dio un RMSE de 234,1 millones para M_1 y 212,4 millones para M_2. Ambos valores quedan dentro del rango de los pliegues y a menos

de una desviación estándar del promedio, aunque son algo más bajos, lo que sugiere que esa partición resultó levemente favorable. En términos simples, las dos validaciones llegan a la misma conclusión, pero la validación cruzada es más confiable: usa todos los avisos para evaluar, entrega cinco mediciones en lugar de una y permite medir cuánto depende el error de la muestra de validación.

(b) Pliegues espaciales

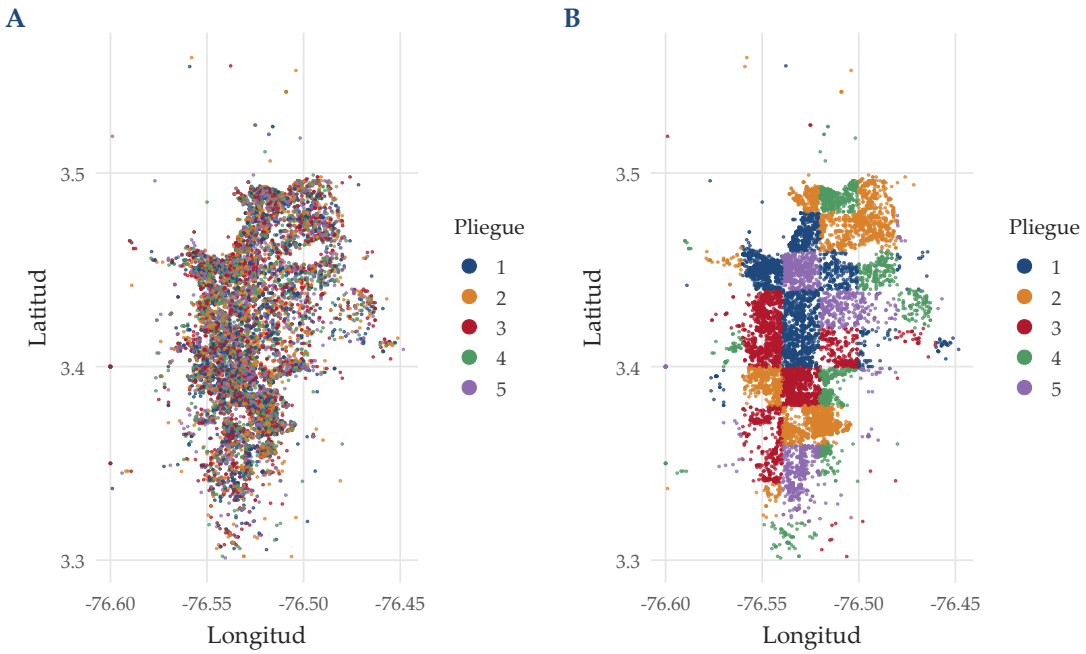


Figura 4. Avisos de entrenamiento según el pliegue en que se validan. Panel A: cinco pliegues aleatorios. Panel B: cinco pliegues espaciales; la ciudad se divide en celdas de 0,02 grados (cerca de 2,2 km) y cada celda entera va a un pliegue (68 celdas con avisos).

La Figura 4 compara los dos esquemas de validación:

- **Pliegues aleatorios (Panel A)**: Los avisos se reparten al azar entre los cinco pliegues, por lo que viviendas vecinas quedan mezcladas en pliegues distintos. Este esquema responde a la pregunta: ¿qué tan bien predice el modelo una vivienda nueva en zonas que ya conoce?
- **Pliegues espaciales (Panel B)**: La ciudad se divide en celdas de 0,02 grados (cerca de 2,2 km de lado) y cada celda entera va a un solo pliegue, de modo que las viviendas vecinas nunca se separan entre entrenamiento y validación. Este esquema responde a la pregunta: ¿qué tan bien predice el modelo en una zona de la ciudad de la que no vio ningún aviso?

Tabla 7. Avisos validados en cada pliegue

	Avisos		
	Aleatorios	Espaciales	Celdas (espaciales)
Pliegue 1	3.056	3.403	14
Pliegue 2	3.056	4.576	14
Pliegue 3	3.055	3.701	14
Pliegue 4	3.055	1.841	13
Pliegue 5	3.055	1.756	13

La Tabla 7 muestra que los pliegues aleatorios quedan del mismo tamaño (entre 3.055 y 3.056 avisos), mientras que los espaciales quedan desbalanceados (entre 1.756 y 4.576 avisos), aunque cada uno recibe 13 o 14 de las 68 celdas. Esto ocurre porque unas celdas concentran muchos más avisos que otras.

Tabla 8. RMSE de M1 y M2 en cada pliegue, aleatorio y espacial

	Pliegues aleatorios			Pliegues espaciales		
	M1	M2	Diferencia	M1	M2	Diferencia
Pliegue 1	243,5	219,1	24,5	292,3	266,8	25,5
Pliegue 2	228,1	203,4	24,7	173,7	160,3	13,4
Pliegue 3	236,4	212,2	24,1	222,8	206,3	16,5
Pliegue 4	240,1	214,7	25,4	207,3	181,5	25,9
Pliegue 5	245,9	225,8	20,1	325,1	298,7	26,4

Nota: RMSE de validación en millones de pesos. Cada pliegue se valida con los modelos ajustados en los otros cuatro. Diferencia = RMSE de M1 menos RMSE de M2 en ese pliegue.

La Tabla 8 presenta el error de cada pliegue en los dos esquemas. De ella destacan dos aspectos clave:

- **Error por pliegue**: Con pliegues aleatorios, el RMSE de M_2 se mueve en un rango estrecho (de 203,4 a 225,8 millones de COP). Con pliegues espaciales, en cambio, va de 160,3 millones en el pliegue 2 a 298,7 millones en el pliegue 5. El mismo patrón se observa en M_1 (de 228,1 a 245,9 frente a 173,7 a 325,1 millones).
- **Comparación de modelos**: M_2 tiene menor error que M_1 en los cinco pliegues de ambos esquemas. Sin embargo, con pliegues aleatorios la diferencia es estable (entre 20,1 y 25,4 millones), mientras que con pliegues espaciales varía más (entre 13,4 y 26,4 millones), lo que muestra que la ventaja de M_2 depende de la zona que se predice.

Tabla 9. RMSE de M1 y M2 con pliegues aleatorios y espaciales

	Pliegues aleatorios		Pliegues espaciales	
Modelo	Promedio	Desv. estándar	Promedio	Desv. estándar
M1: recta con el área	238,8	7,0	244,2	62,5
M2: área, baños, tipo y coordenadas	215,0	8,3	222,7	58,3

Nota: RMSE de validación en millones de pesos: promedio y desviación estándar de los cinco pliegues.

La Tabla 9 resume los dos esquemas. Con pliegues espaciales, el RMSE promedio sube levemente: de 238,8 a 244,2 millones de COP en M_1 y de 215,0 a 222,7 millones en M_2. Sin embargo, la desviación estándar se multiplica: pasa de 7,0 a 62,5 millones en M_1 y de 8,3 a 58,3 millones en M_2. En términos simples, cuando el modelo debe predecir zonas que no vio, su precisión depende mucho de qué parte de la ciudad le toque.

Esquema elegido: En el resto del proyecto usaremos los pliegues espaciales. La Figura 3 de la Parte 1 muestra que los errores del modelo se agrupan por zonas. Por tal razón, la validación aleatoria da una imagen demasiado estable del error, mientras que la espacial mide el desempeño en zonas nuevas y deja ver cuánto puede variar el error según la zona de la ciudad.

(c) Elección de la especificación

Tabla 10. RMSE de cada especificación en cada pliegue (pliegues espaciales)

	Avisos validados	E1	E2	E3	E4
Pliegue 1	3.403	266,8	248,2	252,1	217,9
Pliegue 2	4.576	160,3	156,6	152,1	143,1
Pliegue 3	3.701	206,3	204,3	195,2	177,4
Pliegue 4	1.841	181,5	189,7	166,5	156,3
Pliegue 5	1.756	298,7	288,9	265,2	248,7

Nota: RMSE de validación en millones de pesos. E1: M2 (área, baños, tipo y coordenadas); E2: interacciones con el tipo; E3: polinomios y logaritmos; E4: rica. Cada pliegue se valida con los modelos ajustados en los otros cuatro.

La Tabla 10 presenta el RMSE de las cuatro especificaciones en cada pliegue espacial. Las especificaciones son:

- **E1** (M_2): área, baños, tipo de inmueble y coordenadas.
- **E2** (interacciones): permite que el metro cuadrado y el baño adicional valgan distinto en una casa que en un apartamento.
- **E3** (polinomios y logaritmos): logaritmo del área y su cuadrado, baños y su cuadrado, y

un polinomio de grado 3 en las coordenadas para capturar la forma de los precios en el mapa.

- **E4** (rica): combina E2 y E3 y agrega habitaciones, estrato, año y distancias.

De la tabla destacan dos aspectos clave:

- **E4 gana en todos los pliegues**: tiene el menor error en los cinco, desde 143,1 millones de COP en el pliegue 2 hasta 248,7 millones en el pliegue 5.
- **Las demás no mejoran siempre**: E3 supera a E1 en los cinco pliegues, pero E2 no: en el pliegue 4 su error (189,7 millones) es mayor que el de E1 (181,5 millones). Además, los pliegues 1 y 5 son los más difíciles para todas las especificaciones, lo que confirma que la dificultad depende de la zona que se predice.

Tabla 11. Especificaciones lineales con pliegues espaciales

		Validación (fuera de pliegue)			RMSE entre pliegues	
Especificación	Coef.	RMSE	MAE	R^2	Promedio	Desv. est.
E1. M2: área, baños, tipo y coordenadas	6	219,29	133,20	0,58	222,71	58,27
E2. Interacciones con el tipo	8	212,38	125,56	0,61	217,54	51,72
E3. Polinomios y logaritmos	13	204,31	123,97	0,64	206,22	50,50
E4. Rica: E2 + E3, habitaciones, estrato y distancias	45	185,44	109,28	0,70	188,69	43,90

Nota: RMSE y MAE en millones de pesos, con las predicciones fuera de pliegue de los 15.277 avisos de entrenamiento. Coef.: columnas de la matriz, intercepto incluido. La mediana de habitaciones (E4) se calcula dentro de cada pliegue.

La Tabla 11 resume el desempeño de cada especificación con las predicciones fuera de pliegue:

- **Error de validación**: El RMSE baja de 219,29 millones de COP con E1 a 212,38 con E2, 204,31 con E3 y 185,44 con E4. Es decir, E4 reduce el error en cerca de un 15% frente a E1. El MAE sigue el mismo orden (de 133,20 a 109,28 millones) y el R^2 sube de 0,58 a 0,70.
- **Estabilidad entre pliegues**: E4 también tiene la menor desviación estándar entre pliegues (43,90 millones, frente a 58,27 de E1), por lo que además de equivocarse menos, su error depende menos de la zona.
- **Complejidad**: E4 usa 45 coeficientes frente a 6 de E1. Aun así, como el error se mide en zonas que el modelo no vio, la mejora no es un efecto de sobreajuste: el modelo más rico predice mejor fuera de muestra.

Especificación elegida: E4, la de menor RMSE de validación. Su matriz es la que se amplía en el inciso (d).
¿Por qué preprocesar antes de partir filtra información? Si una transformación que se aprende de los datos (por ejemplo, la mediana para imputar habitaciones) se calcula con toda la muestra, usa también los avisos de validación. Así, el modelo «ve» indirectamente datos que debería

desconocer, y el error de validación sale más optimista de lo real. Por eso la mediana se calcula dentro de cada pliegue (nota de la Tabla 11).

(d) Ridge, Lasso y Elastic Net

Tabla 12. La matriz ampliada (especificación E4): n y p

Bloque	Columnas
Columnas por bloque	
Tipo (Casa)	1
Área, log(área), log(área)², baños, baños², habitaciones y su faltante	7
Estrato (indicadoras de 2 a 6)	5
Interacciones de los anteriores con el tipo	12
Coordenadas: polinomio de grado 3	7
Distancias y área verde, en logaritmo	11
Año del aviso	1
Tamaño	
Total de columnas (p)	44
Avisos de entrenamiento (n)	15.277

Nota: Sin el intercepto, que glmnet no penaliza.

La Tabla 12 presenta la matriz ampliada con la que se estiman Ridge, Lasso y Elastic Net. Es la misma de la especificación E4: 44 columnas (p) repartidas en siete bloques, de los cuales los más grandes son las interacciones con el tipo de inmueble (12 columnas) y las distancias en logaritmo (11 columnas), frente a 15.277 avisos de entrenamiento (n).
En términos simples, hay cerca de 347 avisos por cada columna. Con tantos datos por variable, la regresión sin penalizar ya estima los coeficientes con poca varianza, de modo que la penalización tiene poco margen para mejorar la predicción.

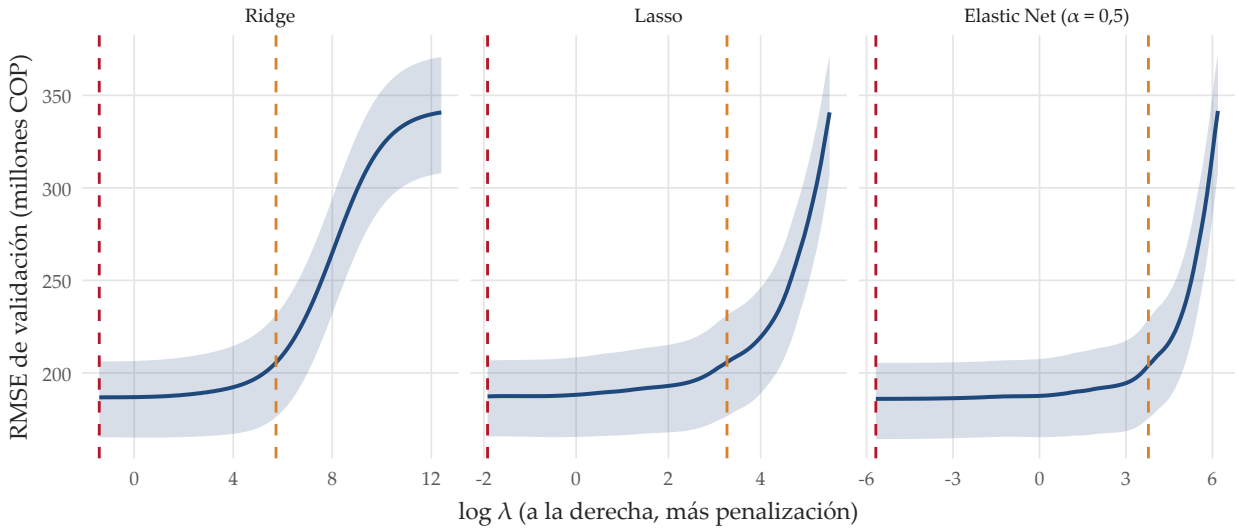


Figura 5. RMSE de validación contra log λ (pliegues espaciales, especificación E4). La banda es ± un error estándar entre pliegues; la línea roja marca λ mín y la naranja, λ 1se.

La Figura 5 muestra el RMSE de validación de Ridge, Lasso y el mejor Elastic Net ($\alpha = 0{,}5$) a medida que aumenta la penalización (λ). De ella destacan tres aspectos clave:

- **Forma de la curva**: Con λ pequeño el error es plano y mínimo; a medida que λ crece, el modelo encoge sus coeficientes hacia cero y el error sube hasta cerca de 340 millones de COP, que es el error de predecir con la media (M_0: 342,86 millones en la Tabla 17).
- **λ mín (línea roja)**: En los tres paneles queda en el extremo izquierdo, es decir, en el menor λ de la grilla. El mejor modelo es el que casi no penaliza.
- **λ 1se (línea naranja)**: Queda más a la derecha, donde la curva empieza a subir. La banda de un error estándar es ancha porque, con pliegues espaciales, el error cambia mucho de una zona a otra; por eso la regla de un error estándar permite una penalización alta.

Tabla 13. RMSE de E4 sin penalizar y de los modelos penalizados en cada pliegue (pliegues espaciales)

			λ mín			λ 1se
	Avisos validados	E4 sin penalizar	Ridge	Lasso	EN ($\alpha = 0{,}5$)	Lasso
Pliegue 1	3.403	217,9	219,8	221,0	218,7	256,6
Pliegue 2	4.576	143,1	143,8	143,6	143,1	145,4
Pliegue 3	3.701	177,4	178,7	179,4	178,0	188,3
Pliegue 4	1.841	156,3	160,4	160,7	159,0	173,2
Pliegue 5	1.756	248,7	248,4	248,9	248,1	281,9

Nota: RMSE de validación en millones de pesos. Todos usan la matriz de E4 y los mismos pliegues; cada pliegue se valida con el modelo ajustado en los otros cuatro. EN: el Elastic Net con menor RMSE en su λ mín (Elastic Net ($\alpha = 0{,}5$)).

La Tabla 13 compara, pliegue por pliegue, la especificación E4 sin penalizar con los modelos penalizados:

- **Con λ mín**: Ridge, Lasso y Elastic Net quedan prácticamente iguales a E4 sin penalizar en los cinco pliegues, con diferencias de máximo 4,3 millones de COP (pliegue 4). Solo en el pliegue 5, Ridge (248,4) y Elastic Net (248,1) quedan levemente por debajo de E4 (248,7).
- **Lasso con λ 1se**: Tiene más error que E4 en todos los pliegues, y la diferencia es mayor en los pliegues más difíciles: 256,6 frente a 217,9 millones en el pliegue 1 y 281,9 frente a 248,7 millones en el pliegue 5.

Tabla 14. Ridge, Lasso y Elastic Net: λ elegido por la validación

	λ mín			λ 1se		
Método	λ	RMSE	Coef. ≠ 0	λ	RMSE	Coef. ≠ 0
Ridge	0,244	186,79	44	308	205,61	44
Elastic Net (α = 0,25)	0,00297	186,00	44	79,8	204,66	14
Elastic Net (α = 0,5)	0,00342	185,98	44	43,8	204,07	13
Elastic Net (α = 0,75)	0,0133	186,00	44	32	204,64	11
Lasso	0,146	187,31	42	26,3	205,78	10

Nota: RMSE de validación en millones de pesos (pliegues espaciales). λ en la escala de glmnet. Coef. ≠ 0: coeficientes distintos de cero, sin el intercepto, con el ajuste en todo el entrenamiento. λ mín es el menor λ de la grilla en: Ridge, Elastic Net (α = 0,25), Elastic Net (α = 0,5), Elastic Net (α = 0,75), Lasso.

La Tabla 14 resume el λ que elige la validación para cada método:

- **λ mín**: Los cinco métodos llegan a un RMSE de entre 185,98 millones (Elastic Net con α = 0,5) y 187,31 millones (Lasso), y conservan casi todas las columnas (44, o 42 en el Lasso). Ninguno mejora a E4 sin penalizar, que tiene un RMSE de 185,44 millones (Tabla 11). Como indica la nota de la tabla, en todos los métodos λ mín es el menor λ de la grilla: con 15.277 avisos y 44 columnas no hay varianza que reducir, y la penalización solo agrega sesgo.
- **λ 1se**: El RMSE sube a entre 204,07 y 205,78 millones, unos 18 millones más que con λ mín, pero los modelos se simplifican: el Lasso pasa a 10 columnas y el Elastic Net con α = 0,5 a 13. Ridge conserva las 44, porque encoge los coeficientes sin llevarlos a cero.

Modelo penalizado elegido: El Elastic Net con α = 0,5 en su λ mín es el mejor de los penalizados (185,98 millones), aunque su desempeño es prácticamente igual al de E4 sin penalizar. Por tal razón, en este problema la regularización no mejora la predicción; su utilidad aparece cuando el número de columnas es grande frente al número de avisos.

(e) k-NN en el mapa y variables que conserva el Lasso

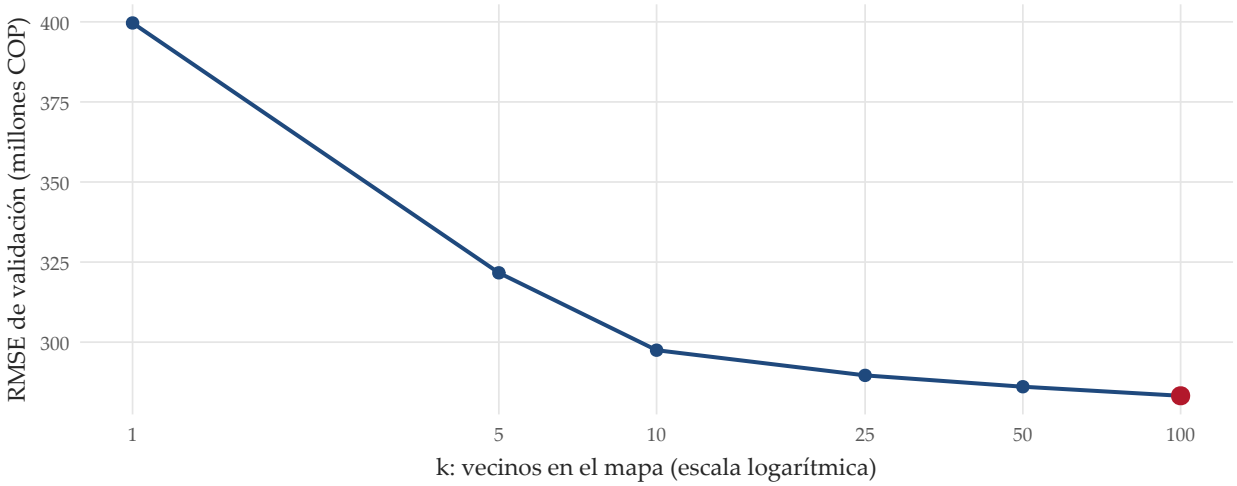


Figura 6. k-NN en el mapa: RMSE de validación según el número de vecinos (pliegues espaciales; lon y lat estandarizadas dentro de cada pliegue). En rojo, el k elegido.

La Figura 6 muestra el RMSE de validación del k-NN, que predice el precio de cada vivienda con el promedio de las k viviendas más cercanas en el mapa (solo longitud y latitud). El error baja con fuerza de $k = 1$ (399,6 millones de COP) a $k = 10$ (297,5 millones) y luego se aplana hasta $k = 100$ (283,3 millones), el valor elegido (punto rojo).
En términos simples, con un solo vecino el modelo copia el precio de una vivienda cercana y arrastra todo su ruido: su error es incluso mayor que el de predecir con la media (M_0: 342,86 millones en la Tabla 17). Al promediar más vecinos, el ruido se compensa y el error baja. Cabe anotar que $k = 100$ es el mayor valor de la grilla evaluada y la curva todavía baja levemente (de 286,1 con $k = 50$ a 283,3).

Tabla 15. RMSE del k-NN en el mapa en cada pliegue (pliegues espaciales)

		Número de vecinos					
	Avisos validados	k = 1	k = 5	k = 10	k = 25	k = 50	k = 100
Pliegue 1	3.403	436,2	374,7	345,0	339,2	332,1	328,4
Pliegue 2	4.576	326,1	249,9	231,8	224,3	221,6	216,0
Pliegue 3	3.701	401,8	313,4	304,3	297,5	295,0	294,4
Pliegue 4	1.841	379,1	268,2	240,7	231,5	227,4	225,9
Pliegue 5	1.756	502,7	427,5	378,7	364,6	364,3	362,3

Nota: RMSE de validación en millones de pesos. Cada pliegue se valida con los vecinos de los otros cuatro; lon y lat se estandarizan con la media y la desviación de los avisos de ajuste.

La Tabla 15 muestra que $k = 100$ tiene el menor error en los cinco pliegues, por lo que la elección no depende de una zona en particular. Sin embargo, el error con $k = 100$ cambia mucho según la zona: va de 216,0 millones de COP en el pliegue 2 a 362,3 millones en el pliegue 5. Como en los incisos anteriores, los pliegues 1 y 5 son los más difíciles de predecir.

Tabla 16. RMSE de validación del k-NN en el mapa

k: vecinos	RMSE de validación (millones COP)
1	399,6
5	321,6
10	297,5
25	289,6
50	286,1
100	283,3

La Tabla 16 resume el RMSE de validación de cada k con todos los avisos: 399,6 millones con $k = 1$, 321,6 con $k = 5$, 297,5 con $k = 10$, 289,6 con $k = 25$, 286,1 con $k = 50$ y 283,3 con $k = 100$. La mayor parte de la mejora ocurre al pasar de 1 a 10 vecinos.

Tabla 17. Todos los modelos hasta aquí, con pliegues espaciales

Modelo	RMSE de validación	MAE de validación	R^2 de validación
M0: media del entrenamiento	342,86	231,66	-0,02
M1: recta con el área	239,63	148,23	0,50
E1. M2: área, baños, tipo y coordenadas	219,29	133,20	0,58
E2. Interacciones con el tipo	212,38	125,56	0,61
E3. Polinomios y logaritmos	204,31	123,97	0,64
E4. Rica: E2 + E3, habitaciones, estrato y distancias	185,44	109,28	0,70
Ridge (λ mín)	186,79	108,92	0,70
Lasso (λ mín)	187,31	109,09	0,69
Lasso (λ 1se)	205,78	118,08	0,63
Elastic Net ($\alpha = 0{,}5$; λ mín)	185,98	109,04	0,70
k-NN en el mapa (k = 100)	283,26	175,83	0,30

Nota: Métricas en millones de pesos con las predicciones fuera de pliegue de los 15.277 avisos de entrenamiento; la misma validación para todos los modelos.

La Tabla 17 reúne todos los modelos con la misma validación (pliegues espaciales):

- **Mejor modelo**: E4 sin penalizar tiene el menor RMSE (185,44 millones de COP) y explica el 70% de la variabilidad del precio (R^2 de 0,70). Muy cerca quedan el Elastic Net con $\alpha = 0{,}5$ (185,98), Ridge (186,79) y Lasso (187,31), todos en su λ mín.
- **Lasso con λ 1se**: Con solo 10 columnas llega a un RMSE de 205,78 millones, similar al de E3 (204,31 millones con 13 coeficientes).

- **k-NN en el mapa**: Con un RMSE de 283,26 millones y un R^2 de 0,30, es claramente peor que los modelos lineales: la ubicación por sí sola explica cerca de un tercio de la variabilidad del precio, pero no reemplaza las características de la vivienda (área, baños, estrato). Además, con pliegues espaciales los vecinos más cercanos de una vivienda validada están siempre en otras celdas, lo que limita lo que el k-NN puede aprender del mapa.
- **Referencia**: Todos los modelos le ganan a la media (M_0: 342,86 millones), y E4 reduce su error en cerca de un 46%.

Tabla 18. Variables que conserva el Lasso en λ 1se (10 de 44)

Columna de la matriz	Descripción	Coeficiente
area	área (m²)	0,673
I(log_area^2)	log(área)²	9,272
banos	baños	44,791
habitaciones	habitaciones (imputadas en el pliegue)	-2,371
estrato6	estrato 6	150,953
cx	longitud	-11,869
I(cy^2)	latitud²	0,379
log_dist_ecoparque_m	log(distancia a: ecoparque)	-4,096
habitaciones:tipoCasa	habitaciones (imputadas en el pliegue) × Casa	-1,754
estrato6:tipoCasa	estrato 6 × Casa	62,622

Nota: Coeficientes en las unidades originales de cada variable (glmnet estandariza por dentro y los devuelve en la escala original), con el ajuste en todo el entrenamiento. Longitud y latitud: coordenadas centradas en un punto fijo de Cali, en centésimas de grado; las distancias, en metros.

La Tabla 18 muestra las 10 columnas, de 44, que conserva el Lasso con λ 1se: el área, log(área)^2, los baños, las habitaciones, el estrato 6, la longitud, la latitud al cuadrado, la distancia al Ecoparque, y las interacciones de las habitaciones y del estrato 6 con el tipo Casa.
Como puntos claves tenemos:

- El estrato 6 es la variable con mayor peso: un aviso en estrato 6 se asocia con 150,95 millones de COP más que uno de estrato 1, y 62,62 millones adicionales si es una casa.
- Las habitaciones tienen signo negativo (−2,37 millones), lo que no significa que una habitación más baje el precio: manteniendo fijos el área y los baños, más habitaciones implican espacios más pequeños.

¿Por qué esto no dice qué variables causan el precio? El Lasso elige las variables que mejor predicen, no las que causan el precio: entre variables correlacionadas (estrato, ubicación y distancias) conserva una y descarta las otras casi al azar, y sus coeficientes están encogidos y dependen de qué otras variables quedaron en el modelo.

3. El modelo final y las predicciones

(a) Modelo final del precio

Tabla 19. Candidatos al modelo final del precio

Modelo	RMSE de validación	MAE de validación	R^2 de validación
Modelos de la Parte 2			
M0: media del entrenamiento	342,86	231,66	-0,02
M1: recta con el área	239,63	148,23	0,50
E1. M2: área, baños, tipo y coordenadas	219,29	133,20	0,58
E2. Interacciones con el tipo	212,38	125,56	0,61
E3. Polinomios y logaritmos	204,31	123,97	0,64
E4. Rica: E2 + E3, habitaciones, estrato y distancias	185,44	109,28	0,70
Ridge (λ mín)	186,79	108,92	0,70
Lasso (λ mín)	187,31	109,09	0,69
Lasso (λ 1se)	205,78	118,08	0,63
Elastic Net (α = 0,5; λ mín)	185,98	109,04	0,70
k-NN en el mapa (k = 100)	283,26	175,83	0,30
Mejoras de E4			
E4 con log(precio)	184,15	99,54	0,70
E5: E4 + estrato × área	182,49	106,75	0,71
E5 con log(precio)	181,82	98,99	0,71

Nota: Métricas en millones de pesos, con las predicciones fuera de pliegue de los 15.277 avisos de entrenamiento y los mismos 5 pliegues espaciales de la Parte 2. Con log(precio), la predicción vuelve a millones con exp() y el factor de Duan. Modelo elegido (menor RMSE): E5 con log(precio).

Elección del modelo final del precio: La Tabla 19 reúne todos los modelos de la Parte 2 y dos mejoras, todos con los mismos cinco pliegues espaciales. El mejor de la Parte 2 era E4 (RMSE de 185,44 millones). Sobre E4 probamos dos mejoras: modelar el logaritmo del precio, que acorta su cola larga a la derecha, y agregar estrato × área, porque el metro cuadrado no vale lo mismo en todos los estratos.

El de menor error es **E5 con log(precio)**, con un RMSE de 181,82 millones, un MAE de 98,99 y un R^2 de 0,712: 47,0 % menos error que predecir con la media (M_0). Aunque el modelo se estima en logaritmos, cada predicción se devuelve a millones con exp() y el factor de Duan, y el RMSE, el MAE y el R^2 se calculan sobre el precio original en millones, para que sean comparables con los demás modelos. Por eso esta fila es comparable con todas las de la tabla de modelos.

Tabla 20. RMSE de los candidatos en cada pliegue espacial

Modelo	Pliegue 1	Pliegue 2	Pliegue 3	Pliegue 4	Pliegue 5
E4 (Parte 2)	217,9	143,1	177,4	156,3	248,7
E4 con log(precio)	214,6	140,4	172,8	161,0	253,7
E5: E4 + estrato × área	214,8	139,7	176,2	149,8	246,0
E5 con log(precio)	212,6	136,5	175,8	152,4	249,1

Nota: RMSE de validación en millones de pesos.

Error por pliegue: La Tabla 20 muestra que el error depende mucho de la zona: con el modelo final va de 136,5 a 249,1 millones según el pliegue. El modelo final tiene menor RMSE que E4 en 4 de los 5 pliegues, así que la mejora no depende de una sola zona de la ciudad.

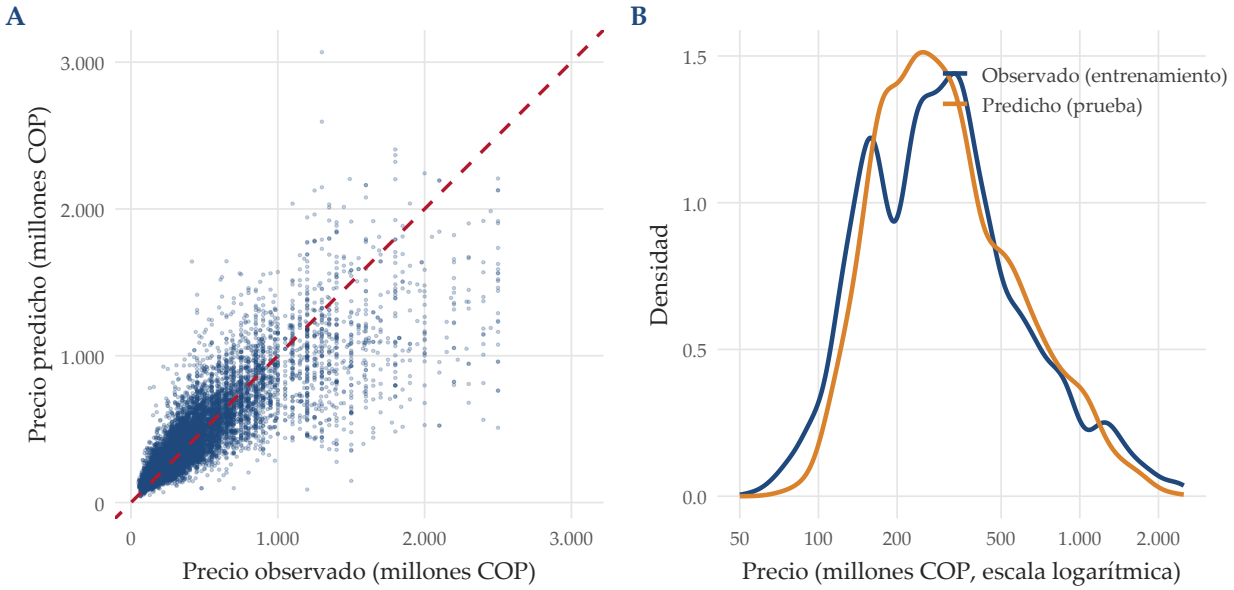


Figura 7. El modelo final (E5 con log(precio)). Panel A: precio predicho fuera de pliegue contra el observado, en los avisos de entrenamiento; la línea punteada es la predicción perfecta. Panel B: densidad del precio observado en el entrenamiento y del precio predicho en los 3.819 avisos de prueba (escala logarítmica).

El modelo final en la validación y en la prueba: En el Panel A de la Figura 7, los puntos se agrupan cerca de la línea de 45° en los precios bajos y medios, y se dispersan más en las viviendas caras, donde el modelo comete los errores más grandes. En el Panel B, el precio predicho para la prueba tiene una forma parecida a la del precio observado en el entrenamiento.

Tabla 21. Precios observados y predichos por el modelo final

	Observado (entrenamiento)	Predicho fuera de pliegue	Predicho (prueba)
Mínimo	50,0	43,0	68,0
Percentil 25	175	198,4	195,1
Mediana	290	296,0	288,6
Media	391,0	388,2	384,7
Percentil 75	450	474,6	467,7
Máximo	2.500	3.067,7	2.394,6

Nota: Millones de pesos. La prueba se usó una sola vez, para predecir con el modelo reajustado con todo el entrenamiento.

Precios observados y predichos: La Tabla 21 muestra que el modelo reproduce bien el centro de la distribución: en la prueba, la mediana predicha es de 288,6 millones (frente a 290,0 observada en el entrenamiento) y la media de 384,7 (frente a 391,0). En los extremos es más prudente: el máximo predicho es 2.394,6 millones, frente a 2.500,0 observado.

(b) Para la avaluadora

Con lo que dice un aviso se puede tasar una vivienda en Cali con un error típico (RMSE) de unos 182 millones de pesos y un error absoluto medio de 99 millones; el modelo explica cerca del 71 % de la variación del precio. Sirve como primer avalúo, no como avalúo final.
El avalúo automático fallará más en las viviendas caras, donde los errores son mayores, y en las zonas con pocos avisos o muy distintas al resto, como muestran los pliegues espaciales. El aviso no dice el estado del inmueble, los acabados, el piso ni la vista, y eso pesa más en el segmento alto.
Lo que el modelo no dice: sus coeficientes y las variables que selecciona no son efectos causales. El modelo aprende asociaciones; por ejemplo, la distancia a un centro comercial también resume el barrio, el estrato y el ingreso de la zona, así que no dice cuánto subiría el precio si se construyera uno al lado. Sirve para predecir, no para responder qué pasaría si cambiara una característica de la vivienda.

Anexo — Tabla de modelos

Misma validación y mismas unidades (millones de pesos) para todos los modelos. Las filas 0 a 2 vienen de la Parte 1, las siguientes de la Parte 2 y la fila final, de la Parte 3.

Tabla 22. Métricas de validación de todos los modelos

Modelo	RMSE de validación	MAE de validación	R^2 de validación
M0: media del entrenamiento	340,94	230,87	-0,00
M1: recta con el área	234,14	146,12	0,53
M2: área, baños, tipo y coordenadas	212,43	130,79	0,61
Mejor especificación lineal (Parte 2): Rica: E2 + E3, habitaciones, estrato y distancias	185,44	109,28	0,70
Ridge / Lasso / Elastic Net (mejor): Elastic Net (α = 0,5), λ mín	185,98	109,04	0,70
k-NN en el mapa (k = 100)	283,26	175,83	0,30
Modelo final: E5 con log(precio)	**181,82**	**98,99**	**0,71**

Nota: RMSE y MAE en millones de pesos. R^2 contra la media de la validación (yardstick::rsq_trad_vec). Filas de la Parte 1: validación 80/20 (semilla 12345); filas de la Parte 2: validación cruzada con cinco pliegues espaciales; fila final (Parte 3): la misma validación cruzada de la Parte 2.

Cierre

Reproducibilidad. El informe completo sale de correr `00_run.R`, en la carpeta del proyecto: corre los análisis que lo necesiten (desde la preparación de los datos, ya incluidos en `01_data/input`), verifica sus resultados y arma este documento a partir de ellos; ninguna cifra se copia a mano. Rutas relativas a la carpeta del proyecto; semilla de la validación: 12345. Versión: R version 4.5.0 (2025-04-11 ucrt); paquetes: rio 1.2.4, dplyr 1.2.1, glmnet 5.1, ggplot2 4.0.1, rmarkdown 2.30.

> **Uso de inteligencia artificial.** Se usó Claude (Anthropic) para diseñar el formato del informe, automatizar su generación a partir de los resultados y organizar la ejecución completa en `00_run.R`, así como para reorganizar este trabajo como un proyecto independiente. Las interpretaciones y conclusiones son del autor.