¿Qué avisos son vivienda de interés social (VIS) en Cali?

Proyecto de machine learning: clasificación de una clase rara

Universidad Icesi — Maestría en Economía · Big Data y Machine Learning para Economía Aplicada

Elkin Mola

12 de noviembre de 2026

---

1. Clasificación: ¿es vivienda de interés social?

(a) Prevalencia de VIS y clasificador trivial

Tabla 1. Prevalencia de VIS y clasificador trivial

	Valor
Avisos de entrenamiento	15.277
Avisos VIS	770
Avisos no VIS	14.507
Prevalencia de VIS (%)	5,0
Accuracy del clasificador trivial (%)	95,0

Nota: El clasificador trivial dice «no VIS» para todos los avisos; su accuracy es 1 menos la prevalencia.

> **Prevalencia y Accuracy Trivial:** La prevalencia de viviendas de interés social (VIS) en la muestra de entrenamiento es de apenas 5,04 %. Por lo tanto, un clasificador trivial que etiquete todos los avisos como “No VIS” lograría un accuracy del 94,96 %. Sin embargo, esta métrica es completamente engañosa en contextos de clases desbalanceadas: aunque el modelo acierta casi siempre, tiene un Recall del 0 %, fracasando por completo en el objetivo real del problema, que es identificar las viviendas VIS.

(b) Regresión logística: ROC, AUC y matriz de confusión

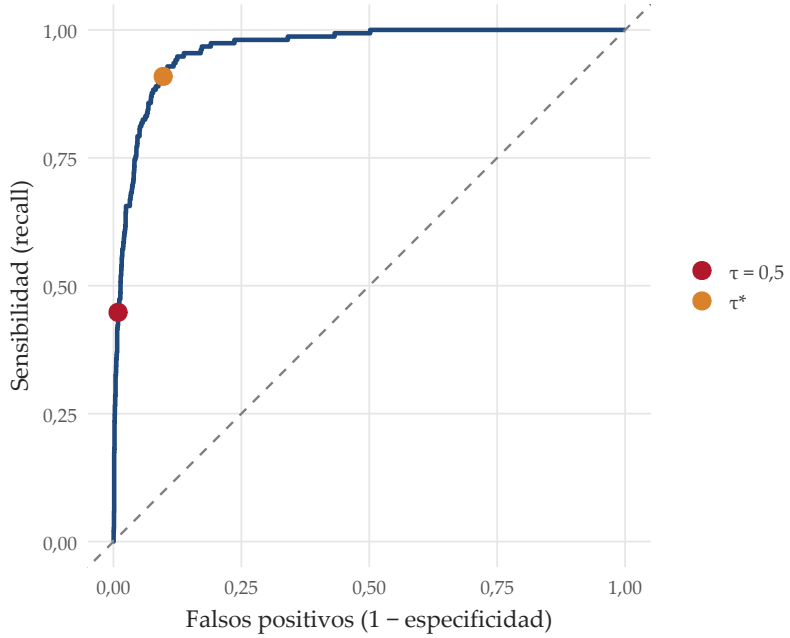


Figura 1. Curva ROC de la logística en la validación (AUC 0,963). La diagonal es el azar; los puntos son los umbrales $\tau = 0{,}5$ y τ^*.

Curva ROC y AUC: La Figura 1 muestra que la curva ROC de la logística queda muy por encima de la diagonal, que representa clasificar al azar. El AUC es de 0,963: si tomamos al azar una vivienda VIS y una no VIS, el modelo le asigna mayor probabilidad a la VIS en el 96,3 % de los casos. Es decir, el modelo ordena muy bien los avisos; el problema del umbral de 0,5 (punto rojo) no es el modelo sino el corte, que deja por debajo 85 de las 154 VIS de la validación.

Tabla 2. Matriz de confusión y métricas con $\tau = 0{,}5$ y con τ^*

Umbral	τ	VP	FN	FP	VN	Recall	Precision	Accuracy	Avisos a revisar	% a revisar	Costo
0,5	0,500	69	85	26	2.876	0,448	0,726	0,964	95	3,109	876
τ^*	0,091	140	14	282	2.620	0,909	0,332	0,903	422	13,809	422

Nota: Sobre la validación (3056 avisos, 154 VIS). Costos supuestos: c_FP = 1 y c_FN = 10.

Desempeño con umbral 0,5: Al estimar la regresión logística y evaluarla en la validación con el umbral por defecto ($\tau = 0{,}5$), el modelo logra encontrar 69 viviendas VIS reales (Verdaderos Positivos). No obstante, este corte estadístico resulta demasiado rigido para la realidad del negocio, ya que deja escapar o no predice 85 viviendas VIS (Falsos Negativos), alcanzando una sensibilidad (Recall) de apenas el 44,8 %.

(c) El umbral con costos y la curva precision–recall

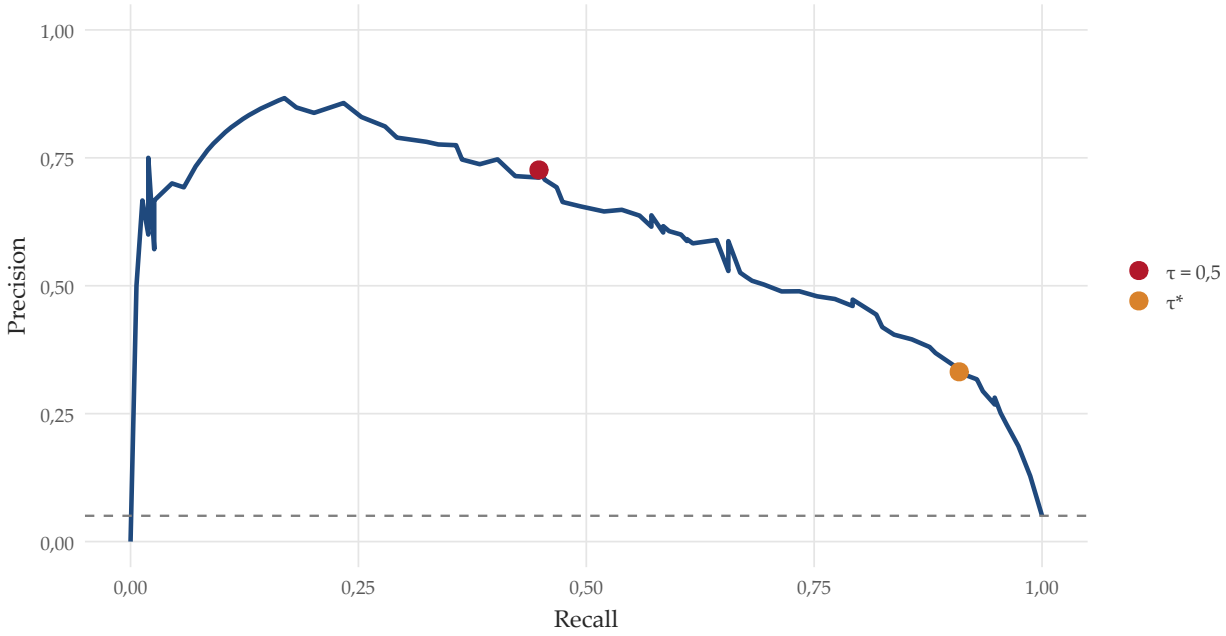


Figura 2. Curva precision–recall de la logística en la validación. La línea punteada es la prevalencia; los puntos son los umbrales $\tau = 0{,}5$ y τ^*.

Recomendación de política (Costos y Umbral Óptimo): Desde la perspectiva de la Secretaría de Vivienda, dejar pasar una vivienda VIS (Falso Negativo) tiene un costo social mucho mayor que revisar manualmente un aviso que resultó no ser VIS (Falso Positivo). Asumiendo una relación de costos de 10 a 1 ($c_{FN} = 10, c_{FP} = 1$), se recomienda ajustar el umbral de decisión a $\tau^* \approx 0{,}09$.

Al implementar este umbral económico, el modelo logra identificar 140 viviendas VIS reales (aumentando la sensibilidad al 90,9 %). Para lograrlo, la secretaría deberá mandar a revisar manualmente un total de 422 avisos (13,8 % de la muestra de validación). Aunque la carga operativa aumenta, el costo total de los errores se reduce de 876 a 422, justificando plenamente la decisión de no dejar a una familia sin subsidio de vivienda vis.

Tabla 3. ¿Qué pasa si cambia el cociente de costos?

c_FN / c_FP	τ^*	VP	FP	FN	Recall	Precision	Avisos a revisar	% a revisar
2	0,333	95	67	59	0,617	0,586	162	5,301
5	0,167	122	148	32	0,792	0,452	270	8,835
10	0,091	140	282	14	0,909	0,332	422	13,809
20	0,048	147	404	7	0,955	0,267	551	18,030
50	0,020	150	661	4	0,974	0,185	811	26,538

Nota: Con c_FP = 1. Cada fila usa su propio $\tau^* = 1/(1 + \text{cociente})$.

Sensibilidad al supuesto de costos: El cociente de 10 a 1 es un supuesto, por eso la Tabla 3 repite el ejercicio con otros cocientes. Si dejar pasar una VIS costara solo el doble que revisar un aviso ($c_{FN}/c_{FP} = 2$, $\tau^* \approx 0{,}33$), la secretaría revisaría 162 avisos y encontraría 95 VIS (recall de 61,7 %). En el otro extremo, si el costo fuera 50 veces mayor ($\tau^* \approx 0{,}02$), revisaría 811 avisos para encontrar 150 VIS (recall de 97,4 %).
Entre más costoso es perder una VIS, más bajo es el umbral: se encuentran más viviendas VIS, pero a cambio de revisar más avisos y con menor precision. Por tal razón, el umbral final depende de cuántos avisos puede revisar la secretaría; con nuestro supuesto de 10 a 1 el umbral queda en 0,09. Más allá de un cociente de 20 se gana muy poco: pasar de 20 a 50 encuentra solo 3 VIS más, a cambio de revisar 260 avisos adicionales.

2. El modelo final de VIS

Tabla 4. Métricas de validación de los modelos de VIS

Modelo	AUC de validación	Log-loss de validación	Brier de validación
V0: siempre la prevalencia	0,5000	0,1997	0,0479
V1: logit con tipo, área, baños y estrato	0,9377	0,1145	0,0330
V2: V1 + coordenadas y año	0,9404	0,1128	0,0325
V3: V2 + distancias (logit de la Parte 1)	0,9405	0,1123	0,0321
V4: Lasso (V3 + curvas)	0,9326	0,1242	0,0355
V5: Ridge (V3 + curvas)	0,9171	0,1393	0,0389
V6: Elastic Net, $\alpha = 0{,}5$ (V3 + curvas)	0,9338	0,1250	0,0358
Modelo final de VIS: V3 (reajustado con todo el entrenamiento)	0,9405	0,1123	0,0321

Nota: Validación cruzada con 5 pliegues espaciales (celdas de 0,02 grados), sobre los 15277 avisos de entrenamiento. AUC: más alto es mejor; log-loss y Brier: más bajo es mejor. V0 no usa predictores. La última fila es el modelo escogido (mayor AUC), reajustado con todo el entrenamiento.

Elección del modelo final de VIS: Para escoger el modelo final comparamos seis modelos con validación cruzada de cinco pliegues espaciales, celdas de 0,02 grados de lado (Tabla 4). En todos el estrato entra como factor, igual que en la Parte 1. Todos superan con amplitud a la referencia sin predictores (V0), que tiene un AUC de 0,5 y un log-loss de 0,1997.

- **Logísticas (V1 a V3):** el AUC es de 0,9377 con tipo, área, baños y estrato (V1), de 0,9404 al agregar coordenadas y año (V2) y de 0,9405 al sumar las distancias que calculamos (V3).
- **Penalizados (V4 a V6):** Lasso, Ridge y Elastic Net obtienen un AUC entre 0,9171 y 0,9338, con un log-loss entre 0,1242 y 0,1393.

Modelo final: escogimos el de mayor AUC con pliegues espaciales, V3: V2 + distancias (logit de la Parte 1). Lo reajustamos con los 15.277 avisos del entrenamiento y con él predecimos `prob_vis` para los 3.819 avisos de prueba.

Tabla 5. AUC de validación con pliegues aleatorios y espaciales

Modelo	AUC, pliegues aleatorios	AUC, pliegues espaciales
V1: logit con tipo, área, baños y estrato	0,9427	0,9377
V2: V1 + coordenadas y año	0,9445	0,9404
V3: V2 + distancias (logit de la Parte 1)	0,9463	0,9405
V4: Lasso (V3 + curvas)	0,9468	0,9326
V5: Ridge (V3 + curvas)	0,9339	0,9171
V6: Elastic Net, $\alpha = 0{,}5$ (V3 + curvas)	0,9470	0,9338

Nota: Pliegues aleatorios estratificados por VIS. Con pliegues espaciales el modelo predice zonas que no vio al ajustarse.

> **Pliegues aleatorios frente a espaciales:** La Tabla 5 compara el AUC de cada modelo con los dos esquemas de validación. Con pliegues espaciales el modelo debe clasificar avisos de zonas de la ciudad que no vio al ajustarse: por ejemplo, V2 pasa de 0,9445 con pliegues aleatorios a 0,9404 con pliegues espaciales, y el Ridge de 0,9339 a 0,9171. Por eso, para identificar VIS en zonas nuevas, escogemos el modelo con pliegues espaciales: es la validación que mejor refleja el reto de identificar VIS en zonas nuevas.

Cierre

Reproducibilidad. El informe completo sale de correr `00_run.R`, en la carpeta del proyecto: corre los análisis que lo necesiten (desde la preparación de los datos, ya incluidos en `01_data/input`), verifica sus resultados y arma este documento a partir de ellos; ninguna cifra se copia a mano. Rutas relativas a la carpeta del proyecto; semilla de la validación: 12345. Versión: R version 4.5.0 (2025-04-11 ucrt); paquetes: rio 1.2.4, dplyr 1.2.1, glmnet 5.1, ggplot2 4.0.1, rmarkdown 2.30.

> **Uso de inteligencia artificial.** Se usó Claude (Anthropic) para diseñar el formato del informe, automatizar su generación a partir de los resultados y organizar la ejecución completa en `00_run.R`, así como para reorganizar este trabajo como un proyecto independiente. Las interpretaciones y conclusiones son del autor.